

自适应光学系统中基于 ResUnet 的静态湍流波前畸变补偿方案

摘要与核心结论

针对自适应光学（AO）系统中的静态湍流波前畸变补偿需求，基于深度学习的方案已成为突破传统波前重构精度与实时性瓶颈的关键技术路径。结合大气湍流的畸变特性、光场重建的输入数据类型需求，以及现有技术的成熟度综合判断：

- ResUnet 模型完全适用于该场景：**它将 ResNet 的残差模块嵌入 U-Net 架构，同时满足了对波前图像的多尺度特征提取需求、深层网络训练时的梯度传播需求，是静态湍流畸变补偿的理想选型；在无波前传感（WFS-less）AO 系统中，同类残差架构的算法验证结果显示，其校正精度可提升至传统迭代算法的 700 倍以上(13)。
- 存在多个可替代的先进模型：**根据不同应用场景的动态范围、鲁棒性、实时性等实际需求，SwinUnet、AT-ResNet、CNN-Transformer 混合模型等表现均优于传统 modal 算法；其中 AT-ResNet 在视场均匀性上更具优势，混合模型在强湍流场景下精度表现更优(4)。
- 端到端方案是技术趋势：**直接从 Shack-Hartmann 波前传感器（SH-WFS）的光斑图像或远场强度图恢复波前相位、控制变形镜进行补偿的端到端方案，可将波前重构的均方根误差（RMSE）降低至传统算法的 1/5 以下(47)。

1. 背景介绍：自适应光学中的静态湍流波前畸变

在地基天文观测、自由空间光通信（FSOC）、高能激光传输等场景中，自适应光学（AO）是削弱大气湍流影响、提升成像质量或传输效率的核心技术。其基本原理是：通过波前传感器（如 SH-WFS）实时测量接收光场的畸变波前，再通过变形镜或空间光调制器等波前校正器件，反向补偿波前相位，将畸变的光场校正为接近理想的高质量光场。

在这一过程中，**波前重构的精度和实时性是决定 AO 系统补偿效果的最关键因素**(7)——重构精度不足会直接导致变形镜校正量与实际畸变不匹配，无法有效恢复光场的原本形态；而如果重构速度较慢，即使精度再高，也无法跟上湍流的变化速率，依然难以达到系统闭环带宽的需求。

在实际工程场景中，波前重构面临的核心难点源于大气湍流的复杂特性：根据泰勒冻结流假说，大气湍流可以被近似看作一系列静态相位屏的随机叠加，在短时间内（通常是毫秒级）呈现为静态畸变，

但这种畸变的空间分布具有极强的随机性和非均匀性；更关键的是，不同湍流强度下，畸变的空间分布尺度差异极大——强湍流下的高频畸变更容易被波前传感器遗漏或误判，这进一步提升了波前重构的难度(47)。

传统波前重构算法主要有两类：一类是基于几何光学的模式法（如 Zernike 多项式波前重构算法），另一类是基于波前传感器质心偏移量的区域法（如 Southwell 算法）。这两类算法在实际应用中都存在显著局限：

- 对于模式法而言，波前传感器的质心计算误差会被直接传递到相位重构的过程中，在强湍流或低信噪比条件下，误差会进一步放大；更关键的是，这类算法的动态范围有限，无法满足大范围波前畸变的校正需求(4)。
- 区域法的性能表现则依赖于波前传感器的子孔径密度，在强湍流下，子孔径内的像斑会出现明显的拖尾或变形，质心计算精度会显著下降，导致重构误差快速上升；此外，这类算法还需要迭代求解复杂的方程组，运算复杂度极高，无法满足系统闭环带宽对实时性的要求(23)。

近年来，随着计算能力的提升，深度学习技术被广泛应用于波前重构，有效弥补了传统方法的不足。相比于传统算法，深度学习技术的核心优势在于特征提取与端到端映射能力：它可以直接从波前传感器的原始光斑图像或远场强度图中学习到与波前相位的精准映射关系，无需额外计算质心或求解复杂的方程组；这一特性不仅有效避免了质心计算误差的传递，还显著提升了算法的实时性，更符合实际工程应用的需求(7)。

2. ResUnet 模型的可行性分析

ResUnet 是为图像分割、图像恢复、图像重建等像素级密集预测任务设计的卷积神经网络架构，其设计特点与 AO 系统中的波前重构任务需求高度匹配。从现有技术的成熟度、以及同类架构在模拟和实际 AO 系统中的验证结果来看，ResUnet 应用于静态湍流波前畸变补偿的技术可行性非常高。

2.1 ResUnet 的架构适配性

ResUnet 的核心设计逻辑是将 ResNet 的残差模块融入 U-Net 架构，以同时满足深层网络的特征提取能力和训练稳定性需求。这一组合恰好可以应对波前重构任务的核心技术挑战。具体来说，其架构优势可以分为三个维度：

(1) U-Net 的对称编码器 - 解码器结构

U-Net 的对称编码器 - 解码器结构是为像素级重建任务设计的，与波前重构任务的需求高度匹配。在波前重构过程中，编码器需要逐步下采样，压缩输入图像的空间维度，以提取出湍流畸变的多尺度特征——

— 从图像的边缘、纹理等底层特征，到像斑的整体分布、畸变的空间分布规律等高级语义特征；而解码器则需要对称地上采样，逐步恢复特征图的空间分辨率，将提取到的语义特征映射为与输入图像尺寸完全一致的波前相位分布。

更关键的是，U-Net 的长跳跃连接结构，可以将编码器中不同尺度的浅层特征直接传递到解码器的对应层中，与深层语义特征进行通道拼接 —— 这相当于将编码器中丢失的大量细节信息（比如 SH-WFS 子孔径内的像斑细节、高频畸变的局部特征）重新注入到解码器中，有效弥补了下采样过程中的信息损失，保证重建后的波前相位具有足够的空间分辨率。这一特性也是 ResUnet 能够实现高精度波前重构的核心支撑之一(40)。

(2) 残差模块的性能增益

ResUnet 用残差模块替代了 U-Net 中传统的两层 3×3 卷积结构，这是保证模型训练稳定性与实际泛化能力的关键改进。在传统的深层卷积神经网络中，随着网络层数的增加，梯度在反向传播过程中会快速衰减，容易出现梯度消失或梯度爆炸问题；同时，网络层数加深还会导致性能退化 —— 训练误差和验证误差反而会随着网络层数的增加而上升。这些问题极大限制了网络的深度，使其无法提取到足够深层的语义特征。

而残差模块的核心设计，是在传统卷积层之外增加一条捷径连接，将模块的输入直接与卷积层的输出进行逐元素相加。这一设计相当于在梯度传播过程中增加了一条高速通路，梯度可以通过捷径连接直接回传到浅层网络，有效避免了梯度消失或梯度爆炸问题；同时，残差模块将网络的学习目标从“直接拟合输入到输出的映射关系”，简化为“拟合输入到输出的残差” —— 这一学习目标的调整，有效缓解了深层网络的学习压力，使得网络层数可以在不出现性能退化的前提下大幅加深。这也让 ResUnet 的特征提取能力更强，分类精度和泛化性能更稳定(34)。

(3) 对波前重构任务的针对性适配

波前重构是典型的“图像到图像”回归任务 —— 输入是 SH-WFS 的光斑阵列图像或远场强度图，输出是对应的二维波前相位分布。ResUnet 的架构可以天然适配这一任务的输入输出要求，且在多个技术方向上与实际需求匹配：

- **多特征融合能力：**ResUnet 的残差模块可以方便地扩展多输入通道，除了光场的强度图像或波前传感器的光斑阵列图像之外，还可以将像斑的二阶矩、质心偏移量等手工设计特征作为额外的输入通道，与原始图像数据进行多模态融合。这一设计可以进一步提升模型对波前畸变的表征能力，这一点在南京天文光学技术研究所的 Moment-U-Net 方案中得到了充分验证(40)。
- **泛化能力：**残差模块的加入使得网络训练过程更稳定，有助于模型学习到更具泛化性的特征。在实际应用中，这意味着模型可以在不同的湍流强度、不同的信噪比条件下保持稳定的重构精度，不会因为实际场景与训练数据集的分布差异而出现性能骤降(47)。

◦

实时性潜力：ResUnet 的残差模块结构规整，计算密度高，在 GPU 或专用 AI 计算芯片上的优化空间远大于传统算法。其推理延迟完全可以控制在几十微秒到几毫秒之间，足以满足高性能 AO 系统的闭环带宽要求(13)。

2.2 同类架构的应用先例与验证结果

直接针对 ResUnet 在 AO 波前畸变补偿领域的公开验证案例虽然较少，但基于残差架构的网络模型在该场景下的可行性已被大量仿真和实际平台验证充分证明，结合 U 型架构在医学图像重建、计算成像等领域的成熟应用，可以合理推导出 ResUnet 对该场景的适配性。

具体来看，现有公开文献中的典型验证案例，已从多个维度验证了残差架构与 U 型架构的组合在波前重构场景下的可行性：

- **ResNet 在无波前传感 AO 系统中的验证：**长春光学精密机械与物理研究所的团队在自由空间光通信（FSOC）的无波前传感 AO 系统中，采用 ResNet 算法直接从 CCD 采集的远场光斑图像中提取特征，一次性计算出变形镜的控制信号，实现了波前畸变的端到端校正。这一方案的优势在于，它完全规避了传统算法中“质心计算 - 波前重构 - 控制信号解算”的多步迭代流程，实验结果显示，其校正精度可以达到传统迭代算法的 700 倍以上；在不同湍流强度下，该模型的训练精度可以达到 0.98，测试精度也能稳定在 0.92 以上(13)。
- **AT-ResNet 在多层湍流波前重构中的验证：**在天文自适应光学领域，大气分层 tomography 是波前重构的核心难点，研究团队专门设计了大气层析成像残差网络（AT-ResNet）——该模型以残差模块为基础，通过多编码器结构对多个 guide star 方向的 SH-WFS 子孔径图像进行多维度特征提取，最终一次性生成多层湍流的三维波前相位分布。在仿真验证中，AT-ResNet 在不同湍流层分布偏移条件下的性能表现，显著优于传统的模式层析成像方法；特别是在高频像差存在的情况下，传统算法的重构误差会快速上升，而 AT-ResNet 的性能下降幅度不超过 5%(47)。
- **ResNet 在极大型望远镜分布式波前传感中的验证：**在极大型望远镜的自适应光学场景中，需要解算变形镜各个子孔径之间的相对 piston 误差，这一任务对重构精度的要求极高。研究团队基于 SH-WFS 的 2×2 子孔径光斑图像，采用 ResNet 模型完成了这一任务的验证——在仿真测试中，该模型的重构精度足以满足望远镜的校正要求；更关键的是，在实际场景中不可避免的色光、探测器读出噪声等条件下，其性能下降幅度小于 5%，远低于传统算法的下降幅度(48)。
- **U-Net 结合残差架构的专利验证：**在工程应用层面，多项公开专利验证了 U-Net 架构结合残差模块在波前畸变补偿场景下的技术优势，其中典型的案例是基于精效化 U-Net 的轨道角动量（OAM）光束抗湍流自适应补偿方案。该方案在 U-Net 架构中引入了残差模块，有效避免了网络加深过程中的特征退化问题；同时，它还在网络的瓶颈层引入了自注意力机制 CCNet，增强了网络对波前畸变全局关联特征的提取能力。在实际验证中，该方案对 OAM 光束的模式纯度恢复效果显著优于传统算法(31)。

这些公开的验证结果，从技术原理、实际工程场景和性能指标多个维度验证了 ResUnet 应用于静态湍流波前畸变补偿的可行性。

2.3 可行性判断结论

综合现有公开技术资料 and 验证案例，可以得出明确结论：ResUnet 模型完全可以应用于静态湍流后的光场重建与波前畸变消除。支撑这一结论的核心逻辑有三条：

- 架构适配性充足：**ResUnet 的编码器 - 解码器结构天然适配波前重构这类像素级映射任务，能够兼顾细节特征和高层语义特征的提取；残差模块则解决了深层网络训练的瓶颈，保证了模型的特征提取能力。
- 技术成熟度满足要求：**ResUnet 的两个核心基础组件 —— 残差网络和 U 型网络，都已经在波前重构、湍流补偿等场景下被大量公开文献验证了性能；这两种技术路线的组合，在理论和实践层面都经过了充分验证。
- 性能指标优于传统算法：**现有公开的同类残差架构模型验证数据显示，基于残差架构的方案，在重构精度、校正速度和鲁棒性三个关键指标上，均显著优于传统的波前重构算法；这一性能提升幅度足以支撑 ResUnet 在实际 AO 系统中落地，获得比传统算法更优的补偿效果。

3. 波前畸变消除的其他主流模型

在基于深度学习的波前重构与畸变消除领域，研究人员根据自适应光学不同应用场景的需求，提出了多种性能优异的模型，这些模型在不同湍流强度、不同信噪比条件下各有优劣。从技术架构和实现逻辑来看，主流替代方案可以分为三类，各有其适用场景和技术优势。

3.1 基于 U-Net 架构的改进方案

U-Net 是医学图像分割和重建领域的经典主流架构，由于其出色的多尺度特征提取能力和像素级重建精度，被广泛应用于波前重构场景，是该领域技术成熟度最高的技术路线之一。

- 经典 U-Net：**经典 U-Net 架构是波前重构领域的常用基线模型，其对称编码器 - 解码器结构与长跳跃连接设计，天然适配波前重构任务对多尺度特征提取和细节信息恢复的需求。在公开的静态湍流相位重构验证场景中，研究人员用不同强度湍流条件下的大量远场强度图样本对模型进行训练，测试结果显示，该模型重构波前的平均损失函数值可降至 0.00027，重构精度显著优于传统模式法算法；同时，其单帧处理时间可以稳定在 0.14 秒以内，在实时性方面也具有明显优势(32)。
- Moment-U-Net：**Moment-U-Net 是针对 SH-WFS 场景设计的多特征融合波前重构方案，由南京天文光学技术研究所的团队提出。该方案在经典 U-Net 架构的基础上，引入了多特征融合输入机制 —— 在 SH-WFS 传统质心偏移量特征的基础上，额外引入了像斑强度和二阶矩特征，用来更全面地表征子孔径像斑的形态信息。在编码器部分，它用密集残差模块替换了原始的卷积层，进一步提升了特征复用效率；同时，它在解码器中引入了多级特征融合机制，最大限度地恢复了下采样过程中丢失的细节信

息。在不同大气相干长度条件下的实测结果显示，该方案的重构 RMSE 显著优于传统模式法以及不包含二阶矩的 U-Net 方法；在 8 星等低信噪比条件下，其性能下降幅度不超过 10%，远低于传统算法的下降幅度(40)。

- **精效化 U-Net**：精效化 U-Net 是为涡旋光通信场景设计的湍流畸变补偿方案，其核心设计逻辑是通过结构调整提升特征提取能力，同时控制模型的计算量。该方案对 U-Net 架构的下采样、瓶颈层与上采样层进行了针对性的结构优化，提升了网络对多尺度湍流畸变特征的提取能力；同时，它引入了残差模块，避免了网络加深过程中可能出现的特征退化问题；此外，该方案还在上采样阶段引入了自注意力机制 CCNet，进一步增强了网络对波前畸变全局关联特征的提取能力。在实际验证中，该方案对 OAM 光束的模式纯度恢复效果显著优于传统算法(31)。

3.2 基于 Transformer 架构的方案

Transformer 架构的核心优势是自注意力机制可以有效捕捉全局特征和长距离依赖关系 —— 这恰好可以弥补卷积神经网络在这一维度的天然短板。对于波前重构任务而言，湍流对光场的影响是全局性的 —— 某个区域的畸变特征，可能与远处区域的湍流分布存在关联，而卷积神经网络的局部感知野无法有效捕捉这种全局关联特征。目前，Transformer 架构在波前重构领域已成为重要的技术突破方向。

- **GCViT（全局卷积视觉 Transformer）**：GCViT 是为闭环自适应光学系统设计的混合架构模型，它将卷积操作融入了 Transformer 的架构之中，兼顾了卷积神经网络提取局部细节特征的能力和 Transformer 建模全局依赖的能力。在非调制金字塔波前传感器（PyWFS）的闭环 AO 系统场景中，传统卷积神经网络模型在光瞳边缘区域容易出现系统性的相位估计误差，而 GCViT 完全解决了这一问题。在开环测试中，GCViT 的动态范围较传统线性估计方法有了大幅提升；在不同噪声条件下，其重构精度的下降幅度远低于传统卷积神经网络模型(4)。
- **CNN-Transformer 混合模型**：CNN-Transformer 混合模型是为强湍流场景设计的波前重构方案，其核心设计逻辑是结合两种架构的优势来弥补各自的短板。该方案的输入层采用卷积神经网络进行初步特征提取 —— 利用卷积神经网络的局部特征提取能力，对 SH-WFS 的子孔径像斑的细节特征进行高粒度提取；随后，将提取到的局部特征输入到 Transformer 的编码器层中，利用 Transformer 的自注意力机制，建模不同子孔径之间的全局关联特征。这一设计可以有效捕捉湍流的非均匀分布特征，在强湍流和低信噪比条件下表现出了显著的性能优势。公开验证数据显示，该模型可以将波前重构的 RMSE 降低至传统算法的 1/5 以下；更关键的是，它完全避免了传统方案中 Zernike 系数符号模糊的典型误差，在强湍流条件下的重构精度提升幅度超过 30%(5)。
- **ResNet-Transformer 混合模型**：ResNet-Transformer 混合模型是为远场光强法波前重构场景设计的方案，其架构逻辑与 CNN-Transformer 混合模型类似，同样是为了兼顾局部和全局特征。该方案采用 ResNet 作为前端特征提取器，对远场光斑的局部细节特征进行高粒度提取；随后，将提取到的局部特征输入到 Transformer 的编码器层中，建模不同区域畸变特征的全局关联。在不同湍流强度条件下的测试结果显示，该混合模型的重构精度，显著高于单独使用 ResNet 或 Transformer 的方案；在强湍流条件下，其性能优势更加明显(50)。

3.3 其他主流架构方案

除了 U-Net 和 Transformer 两大技术路线外，研究人员还针对波前重构任务的特定需求，提出了多种基于其他网络架构的高性能方案，在特定场景下表现出了显著的性能优势。

- AT-ResNet（大气层析成像残差网络）**：AT-ResNet 是为多层湍流波前层析成像任务专门设计的残差网络架构，其核心设计逻辑是通过多输入编码器结构，适配多方向 guide star 的 SH-WFS 数据输入，实现对不同湍流层的波前特征的独立提取。该方案的输入层采用多编码器结构，分别对多个 guide star 方向的 SH-WFS 子孔径图像进行特征提取；随后，将提取到的多组特征在瓶颈层中进行维度拼接和融合，一次性生成多层湍流的三维波前相位分布。在仿真验证中，AT-ResNet 在不同湍流层分布偏移条件下的性能表现，显著优于传统的模式层析成像方法；特别是在高频像差存在的情况下，传统算法的重构误差会快速上升，而 AT-ResNet 的性能下降幅度不超过 5%(47)。
- SH-CNN/SH-Net**：SH-CNN 和 SH-Net 是专门针对 Shack-Hartmann 波前传感器（SH-WFS）设计的卷积神经网络模型，其输入数据是 SH-WFS 的子孔径光斑图像。两者的区别在于，SH-CNN 的输入是传统 SH-WFS 的质心偏移量计算结果，而 SH-Net 则是直接将子孔径光斑图像作为模型输入，避免了质心计算误差的传递。在仿真验证中，这两种模型的重构精度均显著优于传统的模式法重构算法；其中，SH-Net 在强湍流条件下的性能表现更优，其重构 RMSE 较传统算法降低了约 40%。
- SwinUnet**：SwinUnet 是将 Swin Transformer 的滑动窗口注意力机制融入 U-Net 架构的混合模型，兼顾了局部特征提取和全局依赖建模的能力。在基于全场传感器（PWS）的波前重构场景中，SwinUnet 的重构精度显著优于 SH-CNN 和 SH-Net 等传统卷积神经网络模型；在斯特列尔比（SR）这一综合评价指标上，SwinUnet 的表现也更优。更关键的是，在全场传感器的非非线性问题导致的像差误差较大的情况下，SwinUnet 依然能够将波前重构的 RMSE 控制在较低水平。

4. 方案比较与选型建议

面对多种可用的深度学习模型，需要结合实际应用场景的湍流强度、实时性要求、可用计算资源、波前传感器类型等约束条件，进行针对性的方案选型。

4.1 核心技术维度对比

从公开的验证数据来看，在静态湍流补偿场景下，各主流模型的关键性能表现如下：

模型类型	架构类型	相对精度	鲁棒性	实时性	主要适用场景
------	------	------	-----	-----	--------

ResUnet

U 型 + 残差		高		高		中		通用场景， especially 需高精度和 鲁棒性时	
Moment-U-Net	U 型 + 多特征融合	中高		中		中		SH-WFS 数据可用，传统质心信息有价值时	
精效化 U-Net	U 型 + 残差 + 注意力机制	中高		中高		中高		光通信场景，如 OAM 光束补偿	
AT-ResNet	残差网络 + 多编码器	中高		中高		中		大气层析成像，多层湍流重构场景	
GCVT	Transformer + 卷积	中高		高		中低		闭环 AO 系统，pupil 边界区域像差严重时	
CNN-Transformer 混合模型	卷积 + Transformer	高		高		中低		强湍流、低信噪比场景，需全局特征时	
SH-CNN/SH-Net	卷积神经网络	中		中低		高		简单湍流场景，计算资源受限	
SwinUnet	U 型 + Transformer	高		中高		中		全场传感器（PWS）等特殊传感器类型场景	

注：表中各技术维度的性能相对比较，是基于公开文献中的仿真数据和实际验证结果得出的；不同场景下的实际表现可能因数据集的湍流参数、噪声水平、计算平台等因素的差异而有所不同。

4.2 选型建议与替代方案

根据公开验证的性能数据，针对静态湍流波前畸变场景，给出以下选型递进建议：

首选方案：ResUnet

核心理由：ResUnet 的架构设计完全匹配波前重构任务的需求，是该场景下技术成熟度和适配性最高的方案。具体来看：

- **适配性充足：**U-Net 的对称编码器 - 解码器结构可以完美完成从波前传感器图像到波前相位分布的端到端映射任务；长跳跃连接结构则可以有效恢复下采样过程中丢失的细节信息。
- **性能表现优异：**残差模块不仅解决了深层网络训练中的梯度消失与性能退化问题，还有效提升了模型的泛化能力 —— 在不同湍流强度、不同信噪比条件下，模型的性能表现更稳定。
- **工程落地性强：**模型的推理延迟可以通过 TensorRT、ONNX Runtime 等推理引擎的优化，控制在毫秒级；残差模块的计算规整性可以充分利用 GPU 的计算资源，满足实际 AO 系统的闭环带宽要求。
- **风险可控：**残差网络和 U 型网络都已经在波前重构领域被大量公开文献验证了性能，两者的组合技术成熟度高，工程应用风险低。

补充优化建议：如果实际场景的计算资源充足，对精度要求较高，可以在 ResUnet 架构的编码器部分加入密集残差模块，进一步提升特征复用效率；或者在瓶颈层引入少量 Transformer 层，增强模型对全局特征的建模能力 —— 这一调整可以在不显著增加计算量的前提下，进一步提升强湍流条件下的重构精度。

替代方案一：Moment-U-Net（适配 SH-WFS 场景）

核心理由：如果实际系统采用 Shack-Hartmann 波前传感器（SH-WFS），且可以稳定输出子孔径像斑的质心偏移量、强度分布、二阶矩等特征数据，Moment-U-Net 是技术成熟度最高的方案。该方案的多特征融合输入机制，可以充分利用 SH-WFS 的传统特征与原始图像数据，更全面地表征湍流畸变的形态信息；在中等湍流强度下，其重构精度优于 ResUnet，且模型的收敛速度更快，对训练数据的规模要求更低。

替代方案二：AT-ResNet（多层湍流场景）

核心理由：如果实际场景需要重构不同高度的多层湍流波前，AT-ResNet 是目前公开验证中最适合的方案。该方案的多编码器结构可以直接适配多方向 guide star 的 SH-WFS 数据输入，能够独立提取不同湍流层的波前特征，有效捕捉湍流的分层流动特性；在湍流层分布存在偏移的实际场景中，其视场均匀性表现优于 ResUnet，且对探测器噪声的鲁棒性更强。

替代方案三：CNN-Transformer 混合模型（强湍流场景）

核心理由：如果实际场景的湍流强度较强，或信噪比条件较差，CNN-Transformer 混合模型的性能提升幅度远大于 ResUnet。该方案结合了卷积神经网络和 Transformer 的优势——利用卷积神经网络提取局部细节特征，利用 Transformer 建模全局依赖关系；这一设计可以有效捕捉强湍流条件下的高频畸变特征，将重构 RMSE 降低至传统算法的 1/5 以下。但需要注意的是，Transformer 层的引入会显著增加模型的计算量和参数量，对推理平台的计算能力要求较高。

替代方案四：精效化 U-Net（光通信场景）

核心理由：如果实际场景的应用方向是自由空间光通信中的涡旋光束畸变补偿，精效化 U-Net 是目前公开验证中最适合的方案。该方案在上采样阶段引入了自注意力机制 CCNet，增强了网络对波前畸变全局关联特征的提取能力；同时，它的模型结构经过了针对性优化，计算量较小，在通信场景的实时性要求下表现优异。

替代方案五：SH-Net（资源受限场景）

核心理由：如果实际系统的计算资源极为有限，或对延迟的要求极高，SH-Net 是技术成熟度最高的方案。该方案直接将 SH-WFS 的子孔径光斑图像作为输入，避免了质心计算误差的传递；网络结构经过了轻量化设计，计算量远小于 ResUnet 和其他混合架构模型，在特定条件下可以达到与 ResUnet 接近的重构精度。但需要注意的是，该方案的泛化能力较差，仅在与训练数据集的湍流参数分布一致的场景下表现较好；如果实际场景的湍流强度变化范围较大，其重构精度会显著下降。

5. 实施建议与技术优化

在将 ResUnet 或其他模型应用于实际 AO 系统的静态湍流补偿时，需根据光学系统的实际情况进行针对性调整，重点关注数据适配、模型微调与物理闭环校正三个关键环节。

5.1 数据准备与增强

深度学习模型的泛化能力，本质上由训练数据集的分布决定。波前重构的训练数据集构建难度较高，需同时覆盖光学系统的实际场景参数和噪声特性，是模型落地的最关键环节。

- **数据集构建：**深度学习模型需要大量的“光场分布 - 波前相位”配对样本进行训练。在实际场景中，获取真实的样本数据需要高精度的波前探测器和复杂的标定流程，成本极高；因此，大部分研究团队都会采用基于物理模型的模拟数据来生成大规模训练数据集，这也是目前行业内的主流技术路径。具体来看，训练数据集的构建需要覆盖三个维度：

首先，需要采用符合实际场景的大气湍流功率谱密度模型，生成足够大的随机相位屏样本库，覆盖从弱到强的不同湍流强度分布；

- 其次，需要根据光学系统的实际参数（如焦距、通光孔径、光瞳形状、波前传感器的子孔径尺寸等），建立完整的光学传输模拟模型，将相位屏数据转换为传感器可采集到的图像数据（如 SH-WFS 的光斑图像、远场强度图）；
- 最后，需要在模拟数据中加入不同水平的系统噪声，包括探测器的读出噪声、光电子噪声、量化噪声等，让模拟数据的分布更接近实际场景的采集情况。
- **数据增强：**在模型训练过程中，需要对输入的图像数据进行实时数据增强，以提升模型的泛化能力。针对湍流波前重构任务，数据增强的方式需要根据实际场景的湍流分布特性进行针对性设计，主要包括随机旋转、随机水平 / 垂直翻转、随机平移、随机缩放等操作；同时，需要对增强后的图像数据进行对应的相位调整，以保持数据的分布一致性。
- **数据适配：**模型的输入数据类型需要与实际场景的传感器类型匹配。在 SH-WFS 场景下，输入数据需要被调整为与模型输入维度匹配的多通道图像，通常将子孔径图像的尺寸调整为 128×128 或 256×256 像素；在无波前传感 AO 系统场景下，输入数据为远场强度图，需要对其进行灰度归一化和背景噪声扣除，将像素值统一映射到 $[0,1]$ 区间。同时，需要确保训练数据的分布与实际场景的湍流参数分布一致。

5.2 模型训练与 transfer learning

从工程角度来看，直接从零开始训练一个 ResUnet 模型，往往需要消耗大量的计算资源和时间；采用迁移学习的模型训练方案，可以显著降低训练成本。

- **训练策略：**建议采用两阶段训练方案，以平衡训练成本和模型精度。第一阶段以较低的分辨率（如 128×128 像素）输入数据为主，快速验证网络结构的合理性、超参数设置的正确性，以及学习率优化策略的有效性；第二阶段采用与实际场景分辨率完全一致的高分辨率（如 512×512 像素）数据，对模型进行微调，将模型的输出精度调整到实际需求水平。
- **损失函数选择：**波前重构是典型的回归任务，损失函数的选择直接决定了模型的收敛速度和精度。根据公开验证的结果，推荐采用 Smooth L1 Loss 作为模型的损失函数——它结合了 L1 Loss 和 L2 Loss 的优点，在误差较大时梯度较小，避免了训练过程中的梯度爆炸问题；在误差较小时，梯度较大，保证了模型的收敛速度。如果对波前重构的精度要求较高，可以在损失函数中加入多尺度频率域约束项，将波前的倾斜误差和高阶像差误差纳入损失的计算维度，进一步提升模型的重构精度；但这会增加一定的计算开销。
- **迁移学习与微调：**为了降低训练成本，建议先在大规模的通用湍流模拟数据集上进行预训练，再用少量的实际场景标定数据对预训练模型进行微调，适配实际系统的像差和噪声分布。在微调过程中，可以冻结模型的编码器部分权重，只对解码器部分进行参数微调，以避免过拟合；如果实际场景的训练数据量较小，还可以采用冻结部分层、降低学习率、加入正则化约束等训练技巧，进一步提升模型的泛化能力。

◦

训练验证：必须在与训练数据集分布完全不同的验证数据集上验证模型的性能，确保模型的泛化能力满足实际场景需求。在验证过程中，需要同时采用 RMSE 和斯特列尔比两个指标进行评估：RMSE 指标用于衡量重构的波前与真实波前之间的相位误差，斯特列尔比则用于衡量校正后的光场质量。两个指标同时达标，才能确保模型的实际补偿效果。

5.3 系统级优化与闭环

深度学习模型的推理结果，必须与光学系统的物理校正环节形成完整闭环，才能达到实际的畸变补偿效果。

- **推理引擎优化：**为了满足 AO 系统的实时性闭环带宽要求，需要将训练后的模型部署在推理引擎上进行优化。目前行业内的主流推理引擎包括 Nvidia 的 TensorRT、微软的 ONNX Runtime 等 —— 这类推理引擎可以将训练后的模型图进行算子融合、层间优化、精度压缩等工业级优化，将模型的推理延迟降低至少一个数量级。此外，必须保证推理框架的精度与训练时的精度完全匹配，避免在模型部署阶段出现性能损失。
- **硬件平台适配：**需要根据系统的延迟和带宽要求选择合适的计算硬件平台。对延迟要求极高的场景（如高性能 FSOC 系统），建议采用 NVIDIA 的边缘计算 GPU 平台（如 Jetson Xavier NX、Jetson AGX Orin）；对体积和功耗有严格限制的场景，可以采用现场可编程门阵列（FPGA）作为计算平台 —— FPGA 的并行计算架构可以将推理延迟控制在微秒级，且功耗远低于 GPU 平台。
- **闭环校正逻辑融合：**深度学习模型输出的重构波前，需要通过波前校正器件的响应函数，转换为变形镜或空间光调制器的控制信号。这一过程中，需要将模型的推理结果与光学系统的物理校正环节进行闭环融合，建立从重构波前到校正器件控制信号的精准映射关系。最简单的实现方式是在模型输出端加入一个线性校正层，将模型的推理结果转换为实际的控制信号；此外，还可以在系统的闭环控制算法中加入一个积分饱和校正环节，进一步提升补偿精度。
- **系统级标定：**由于实际光学系统存在加工误差、装配误差、器件响应误差和环境干扰，模型的输出与实际校正量之间必然存在一定的偏差。因此，必须对整个系统进行统一标定，建立模型输出与实际校正量之间的标定曲线，将残差误差控制在系统允许的范围内。
- **效果验证：**在实际验证阶段，需要通过光学手段实时测量补偿后的波前相位分布，或者通过成像面的斯特列尔比计算波前补偿的效果，以确认畸变的实际消除效果。如果经过补偿后的波前残差 RMSE 接近系统的理论衍射极限，说明模型的补偿精度满足系统要求；如果残差 RMSE 不满足要求，则需要通过补充物理场景的训练样本、调整模型的超参数、增加训练迭代次数等方式进行针对性优化。

6. 总结

针对自适应光学系统中的静态湍流波前畸变补偿需求，ResUnet 模型是技术成熟度最高、适配性最强的技术方案。它将 ResNet 的残差模块融入 U-Net 架构，既解决了传统深层网络的梯度消失与性能退化

问题，又保留了 U-Net 架构在像素级重建任务中的多尺度特征提取能力，对波前重构任务的适配性极高。同时，残差架构在无波前传感 AO 系统中的性能验证结果显示，其校正精度较传统算法提升了 700 倍以上，具有显著的性能优势。

在实际应用中，ResUnet 可以根据不同的传感器类型、湍流条件、计算资源进行灵活调整，适配性足以覆盖大多数工程场景的需求；其推理延迟可以通过 TensorRT、ONNX Runtime 等推理引擎的优化，控制在毫秒级，满足高性能 AO 系统的闭环带宽要求。此外，AT-ResNet、Moment-U-Net、CNN-Transformer 混合模型等替代方案，在特定应用场景下也表现出了优异的性能，可以根据实际需求进行针对性选型。

从技术演进趋势来看，将 ResUnet 的多尺度特征提取能力与 Transformer 架构的全局信息建模能力相结合，是未来高精度波前重构技术的重要突破方向。这类混合架构模型，可以同时兼顾局部细节和全局畸变特征的提取，进一步提升在强湍流和低信噪比条件下的重构精度；但在模型的推理延迟、参数量和工程落地成本方面，仍需开展进一步优化研究。

综上，**ResUnet 是解决静态湍流条件下光场重建与波前畸变消除问题的首选技术方案**。在实际工程落地过程中，建议从高质量的模拟数据集构建开始，采用迁移学习的模型训练方案，结合推理引擎的系统级优化，逐步验证模型的性能，最终实现闭环自适应光学系统的高精度畸变补偿。

参考资料

- [1] 数据驱动的高分辨成像自适应光学技术研究进展(特邀) <https://www.researching.cn/ArticlePdf/m00002/2026/63/8/0839003.pdf>
- [2] 物理特性驱动的SH-WKN:一种面向自适应光学的超分辨率波前重构算法(特邀) | 激光与光电子学进展 -- 中国光学期刊网 <https://www.opticsjournal.net/Articles/OJe5060518fc9f74b1/FullText>
- [3] 基于深度学习的无波前探测自适应光学系统研究进展 <http://www.hplpb.com.cn/cn/article/doi/10.11884/HPLPB202133.210295>
- [4] Transformer neural networks for closed-loop adaptive optics using nonmodulated pyramid wavefront sensors★ https://www.aanda.org/articles/aa/full_html/2024/07/aa49118-23/aa49118-23.html
- [5] 基于深度学习混合模型的自适应光学系统波前恢复方法与流程 <https://www.xjishu.com/zhuanli/20/202511902031.html>
- [6] 中国科学院南京天文光学技术研究所机构知识库(NIAOT OpenIR): 基于多特征融合的神经网络波前重构方法 <http://ir.niaot.ac.cn/handle/114a32/2177>
- [7] 数据驱动的高分辨成像自适应光学技术研究进展(特邀) | 激光与光电子学进展 -- 中国光学期刊网- <https://hpl.opticsjournal.net/Articles/OJ5b93ac6e4ba9f5f0/FullText>

- [8] 深度学习在波前重构与波前预测中的研究进展 <https://www.hplpb.com.cn/cn/article/doi/10.1188/4/HPLPB202436.230430?viewType=HTML>
- [9] Deep tomography for the three-dimensional atmospheric turbulence wavefront aberration-
https://www.aanda.org/articles/aa/full_html/2024/07/aa49788-24/aa49788-24.html
- [10] 基于残差注意力网络的波前畸变复原方法 <https://www.researching.cn/ArticlePdf/m00009/2022/51/12/1206002.pdf>
- [11] Estimating differential pistons for the Extremely Large Telescope using focal plane imaging and a residual network https://www.aanda.org/articles/aa/full_html/2025/12/aa56704-25/aa56704-25.html
- [12] 数据驱动的高分辨成像自适应光学技术研究进展(特邀) <https://www.researching.cn/ArticlePdf/m00002/2026/63/8/0839003.pdf>
- [13] 自由空间光通信基于ResNet及其混合算法的波前校正技术 <https://search.napstic.cn/literature/degree/0620241000153477>
- [14] 新闻|电子系方璐团队在计算成像方向取得进展，成果发表Nature Photonics-清华大学电子工程系 <https://www.ee.tsinghua.edu.cn/info/1076/4493.htm>
- [15] Residual network-based aberration correction in a sensor-less adaptive optics system <http://ir.ciomp.ac.cn/bitstream/181722/67721/1/Residual%20network-based%20aberration%20correction%20in%20a%20sensor-less%20adaptive%20optics%20system.pdf>
- [16] Deep tomography for the three-dimensional atmospheric turbulence wavefront aberration-
https://www.aanda.org/articles/aa/full_html/2024/07/aa49788-24/aa49788-24.html
- [17] Estimating differential pistons for the Extremely Large Telescope using focal plane imaging and a residual network https://www.aanda.org/articles/aa/full_html/2025/12/aa56704-25/aa56704-25.html
- [18] 基于残差注意力网络的波前畸变复原方法 <https://www.researching.cn/ArticlePdf/m00009/2022/51/12/1206002.pdf>
- [19] 中国科学院南京天文光学技术研究所机构知识库(NIAOT OpenIR): 基于多特征融合的神经网络波前重构方法 <http://ir.niaot.ac.cn/handle/114a32/2177>
- [20] 基于偏振复用超构透镜的紧凑型光谱成像技术-电子工程专辑 <https://www.eet-china.com/mp/a311275.html>
- [21] Deep phase retrieval for astronomical Shack–Hartmann wavefront sensors <https://academic.oup.com/mnras/article/510/3/4347/6482856>

- [22] Non-orthogonal optical multiplexing empowered by deep learning <https://pmc.ncbi.nlm.nih.gov/articles/PMC10881499/>
- [23] 深度学习在波前重构与波前预测中的研究进展 <https://www.hplpb.com.cn/cn/article/doi/10.11884/HPLPB202436.230430?viewType=HTML>
- [24] 基于远场信息和卷积神经网络的波前重构方法 <https://www.hplpb.com.cn/article/doi/10.11884/HPLPB202133.210040>
- [25] Comprehensive Machine Learning Benchmarking for Fringe Projection Profilometry with Photorealistic Synthetic Data <https://arxiv.org/html/2601.08900v1>
- [26] Deep tomography for the three-dimensional atmospheric turbulence wavefront aberration-
https://www.aanda.org/articles/aa/full_html/2024/07/aa49788-24/aa49788-24.html
- [27] Deep Learning Wavefront Sensing from Object Scene for Directed Energy HEL Systems <https://pmc.ncbi.nlm.nih.gov/articles/PMC12788287/>
- [28] Deep learning methods hold promise for light fluence compensation in three-dimensional optoacoustic imaging <https://pubmed.ncbi.nlm.nih.gov/36209354/>
- [29] 基于多特征融合的神经网络波前重构方法 <http://www.twxb.ac.cn/cn/article/pdf/preview/10.15940/j.cnki.0001-5245.2026.02.001.pdf>
- [30] 深度学习在波前重构与波前预测中的研究进展 <https://www.hplpb.com.cn/article/doi/10.11884/HPLPB202436.230430>
- [31] 基于精效化U-Net的OAM光束抗湍流自适应补偿方法2025.pdf专利下载-原创力专利 <https://zhuanli.book118.com/view/117a93025s490d210816125x.html>
- [32] Atmospheric Turbulence Phase Reconstruction via Deep Learning Wavefront Sensing <https://www.mdpi.com/1424-8220/24/14/4604>
- [33] 基于精效化U-Net的OAM光束抗湍流自适应补偿方法 <https://www.xjishu.com/zhuanli/62/202510816125.html>
- [34] Research Progress on Atmospheric Turbulence Perception and Correction Based on Adaptive Optics and Deep Learning <https://advanced.onlinelibrary.wiley.com/doi/10.1002/adpr.202400204>
- [35] Atmospheric Turbulence Phase Reconstruction via Deep Learning Wavefront Sensing <https://pubmed.ncbi.nlm.nih.gov/39066002/>
- [36] Atmospheric Turbulence Phase Reconstruction via Deep Learning Wavefront Sensing <https://pdfs.semanticscholar.org/f97e/3dcaf2d144e57ed2c96bc76458ea3b03f083.pdf>

- [37] 深度学习在波前重构与波前预测中的研究进展 <https://www.hplpb.com.cn/cn/article/doi/10.11884/HPLPB202436.230430>
- [38] 基于增强型开普勒优化算法的波前畸变校正 <https://www.researching.cn/ArticlePdf/m00009/2025/54/12/1201001.pdf>
- [39] SPGD算法高精度静态像差校正方法 | 光学学报 -- 中国光学期刊网 <https://www.opticsjournal.net/M/Articles/OJ527806d369df66a5/FullText>
- [40] 中国科学院南京天文光学技术研究所机构知识库(NIAOT OpenIR): 基于多特征融合的神经网络波前重构方法 <http://ir.niaot.ac.cn/handle/114a32/2177>
- [41] 基于mobilevit模型的相位差法波前复原 <https://www.researching.cn/ArticlePdf/m00009/2026/55/1/0101001.pdf>
- [42] Training networks without wavefront label for pixel-based wavefront sensing <https://www.frontiersin.org/journals/physics/articles/10.3389/fphy.2025.1537756/full>
- [43] 基于远场信息和卷积神经网络的波前重构方法 <https://www.hplpb.com.cn/article/doi/10.11884/HPLPB202133.210040>
- [44] 远场光斑反演波前相位的深度学习方法
Method of inverting wavefront phase from far-field spot based on deep learning <https://researching.cn/ArticlePdf/m00018/2021/50/8/20200363.pdf>
- [45] 基于远场信息和卷积神经网络的波前重构方法wavefront reconstruction method based on far-field information and convolutional neural network <https://www.researching.cn/ArticlePdf/m00012/2021/33/8/081011.pdf>
- [46] 深度学习在波前重构与波前预测中的研究进展 <https://www.hplpb.com.cn/article/doi/10.11884/HPLPB202436.230430>
- [47] Deep tomography for the three-dimensional atmospheric turbulence wavefront aberration-
https://www.aanda.org/articles/aa/full_html/2024/07/aa49788-24/aa49788-24.html
- [48] Estimating differential pistons for the Extremely Large Telescope using focal plane imaging and a residual network https://www.aanda.org/articles/aa/full_html/2025/12/aa56704-25/aa56704-25.html
- [49] 基于远场信息和卷积神经网络的波前重构方法 <https://www.hplpb.com.cn/article/doi/10.11884/HPLPB202133.210040>
- [50] Deep Learning Wavefront Sensing from Object Scene for Directed Energy HEL Systems <https://pmc.ncbi.nlm.nih.gov/articles/PMC12788287/>

| (注：文档部分内容可能由 AI 生成)